Микроэконометрика

Домашнее задание №1

София Стефанюк

2026

Описание данных

Как принято в заданиях подобного рода, до того, как начать строить модели необходимо проанализировать данные, представленные в датасете.

Наша выборка содержит информацию о 5000 игроках, участвовавших в закрытом бета-тестировании градостроительного симулятора кошек и собак. Пропущенных значений не неблюдается. Расшифровка переменных приведена в приложении (таблица 12)

Теперь посмотрим на описательные статистики непрерывных переменных, чтобы что-то понимать в будущем:

Таблица 1: Описательные статистики непрерывных переменных

	Среднее	Ст. откл.	Мин.	Медиана	Макс.
Доход, руб.	28324.4	22459.2	2000.0	22000.0	323000.0
Возраст, лет	34.9	14.9	18.0	31.0	68.0
Игровые часы в неделю	10.0	8.3	1.0	8.0	62.0
Число багов	5.0	2.3	0.0	5.0	14.0
Стоимость компьютера, тыс. руб.	82.3	39.4	32.0	74.0	225.0

Запоминаем минимальные и максимальные значения переменных и двигаемся дальше.

Задание нас просит отдельно проанализировать уровень удовлетворенности, в зависимости от животного персонажа, поэтому мы сразу и посмотрим на распределение этой самой удовлетворенности (таблица 2)

Таблица 2: Распределение удовлетворенности игрой по группам выбора

	Удовлетворенность игрой		
Выбор	низкая	средняя	высокая
Собаки (`choice`=0)	0.476	0.337	0.187
Кошки (`choice`=1)	0.073	0.207	0.720

Из таблицы 2 видно, что игроки, проходившие игру за кошек, значительно чаще сообщают о высокой удовлетворенности, чем игроки, выбравшие собак.

Часть 1. Теория и гипотезы

Задание 1.1.

Выберите независимые переменные. Кратко теоретически обоснуйте выбор каждой из них: не обязательно со ссылками на литературу, достаточно здравого смысла. Укажите и кратко обоснуйте предполагаемые направления эффектов. При этом вам понадобится как минимум одна непрерывная переменная (например, возраст или доход) и одна дамми переменная (например, половая принадлежность или брак). Не рекомендуется брать больше трех различных независимых переменных, не считая их нелинейных преобразований: квадрат, логарифм, перемножение с целью получения переменной взаимодействия и т.д.

Переменные, которые я бы хотела взять: возраст, доход и выбор персонажа. Так, например, у молодых высокая толерантность к качеству игры и они могут быть удовлетворенными от простого нахождения рядом с компьютером, высокий доход наоборот позволяет играть в самые крутые игры, а выбор персонажа как раз ответит нам на отдельный вопрос условия. По направлениям ожидаемых эффектов получается следующее: возраст - минус, доход - минус, выбор кошки - плюс (я думаю, они популярнее).

Задание 1.2.

Сформулируйте по крайней мере одну гипотезу о наличии эффекта взаимодействия и еще одну о наличии нелинейного эффекта (например, квадратичного). Теоретически обоснуйте выдвигаемые вами гипотезы. Включите соответствующие переменные в вашу модель. При этом переменная, входящая нелинейно, должна иметь и линейную часть, например, $\beta_1 X_1 + \beta_2 X_1^2$.

Гипотеза о нелинейном (квадратичном) эффекте возраста. Молодые игроки предъявляют к игре невысокие требования и любят стримить нововыходящие игры любого жанра и качества. С возрастом, к сожалению, появляются работа, семья и дети, поэтому карьеру стримера приходится заканчивать, а требования к качеству игр растет, чтобы хотя бы они после работы не бесили. Однако в старшем возрасте свободного времени снова становится больше и удовлетворенность может вырасти. Таким образом, ожидается отрицательный коэффициент при `age` и положительный коэффициент при $\texttt{age}^2$.

Гипотеза об эффекте взаимодействия выбора персонажей и дохода. Богатые игроки хуже реагируют на котиков в играх, потому что они более требовательны. Они привыкли к дорогим играм и ценят качество, следовательно, ожидается отрицательный коэффициент при переменной взаимодействия $\texttt{choice} \cdot \texttt{income}$.

С учетом выдвинутых гипотез модель принимает вид:

$$\text{satisfied}_i = \beta_0 + \beta_1 \,\text{choice}_i + \beta_2 \,\text{income}_i + \beta_3 \,\text{choice}_i \cdot \text{income}_i + \beta_4 \,\text{age}_i + \beta_5 \,\text{age}_i^2 + \varepsilon_i, \quad (1)$$

где $i = 1, \ldots, 5000$ - номер игрока, satisfied_i - бинарная переменная удовлетворенности игрой, $\beta_0, \ldots, \beta_5$ - неизвестные параметры, ε_i - случайная ошибка. Ожидаемые знаки: $\beta_1 > 0$, $\beta_2 < 0$, $\beta_3 < 0$, $\beta_4 < 0$, $\beta_5 > 0$.

Задание 1.3.

Создайте новую бинарную переменную на удовлетворенность игрой, объединив любые две соседние категории переменной «game». Данная переменная выступает в качестве зависимой при оценивании моделей бинарного выбора. Для краткости далее в условии будем считать, что 1 значение соответствует тому, что индивид удовлетворен игрой, а 0 тому, что он не удовлетворен. Приведите и далее в тексте вашей работы используйте более подробную содержательную интерпретацию 1 и 0 значений созданной вами переменной, учитывающую то, что к одному из них относятся сразу две категории.

На основе переменной `game` создана бинарная переменная удовлетворкнности игрой путем объединения средней и высокой категорий:

$$\text{satisfied}_i = \begin{cases} 1, & \text{если } \texttt{game}_i \in \{1, 2\} \text{ (средняя или высокая удовлетворенность),} \\ 0, & \text{если } \texttt{game}_i = 0 \text{ (низкая удовлетворенность).} \end{cases} \quad (2)$$

Такое объединение обосновано тем, что высокую оценку игроки, как правило, ставят лишь при самом положительном впечатлении от игры (так называемом вау-эффекте), тогда как средняя оценка означает, что игра в целом устроила игрока и, по моему мнению, ближе к высокой, чем к низкой.

Далее значение $\text{satisfied}_i = 1$ интерпретируется как «игра не разочаровала игрока» , а значение $\text{satisfied}_i = 0$ - как «игра разочаровала игрока». В выборке игра не разочаровала 75,4% игроков, а разочаровала - 24,6%.

Часть 2. Линейно-вероятностная модель

Задание 2.1.

Оцените линейно-вероятностную модель бинарного выбора. Предварительно запишите регрессионное уравнение. Укажите оцениваемые параметры и метод получения оценок. Результат представьте в форме таблицы (можно, например, использовать выдачу из stata, R или python).

Полученная линейно-вероятностная модель выглядит следующим образом:

$$P(\text{satisfied}_i = 1 \mid X_i) = E[\text{satisfied}_i \mid X_i] = \beta_0 + \beta_1 \,\text{choice}_i + \beta_2 \,\text{income}_i + \beta_3 \,\text{choice}_i \cdot \text{income}_i + \beta_4 \,\text{age}_i + \beta_5 \,\text{age}_i^2, \tag{3}$$

где X_i - вектор регрессоров игрока i, доход income_i измеряется в тыс. руб., остальные обозначения совпадают с уравнением (1).

Оцениваемые параметры: $\beta = (\beta_0, \beta_1, \ldots, \beta_5)^\top$. Оценки получены методом наименьших квадратов (МНК):

$$\hat{\beta} = \arg\min_{\beta} \sum_{i=1}^{n} \left(\text{satisfied}_i - X_i^\top \beta\right)^2 = (X^\top X)^{-1} X^\top y,$$

где X - матрица регрессоров размера $n \times 6$ (первый столбец - единицы), y - вектор значений satisfied_i, $n = 5000$. Результаты оценивания представлены в таблице 3.

Таблица 3: Оценки линейно-вероятностной модели (МНК)

	Оценка	Ст. ошибка	t	p-value
Константа	0.27804	0.04040	6.883	< 0.001
Выбор кошек (choice)	0.43647	0.01741	25.070	< 0.001
Доход, тыс. руб.	0.00246	0.00039	6.304	< 0.001
Выбор кошек × доход	-0.00164	0.00049	-3.322	0.001
Возраст, лет	0.00769	0.00222	3.461	0.001
Возраст^2	-0.00006	0.00003	-2.075	0.038
Число наблюдений: 5000; $R^2 = 0.235$; $F = 306.5$ (p-value < 0.001)				

Согласно таблице 3, все коэффициенты модели значимы на уровне 5%. Знаки оценок при выборе кошек и переменной взаимодействия совпадают с ожидаемыми, тогда как знаки при доходе и возрасте противоположны выдвинутым гипотезам.

Задание 2.2.

Перечислите основные недостатки линейно-вероятностной модели. Напишите, можно ли интерпретировать оценки коэффициентов, их значимость (с использованием обычной оценки ковариационной матрицы), коэффициент детерминации и F-статистику? Если да, то приведите интерпретацию, а если нет, то объясните (без непосредственной реализации), почему она в данном случае невозможна и предложите альтернативный способ оценки качества модели.

Первый очевидный недостатой линейно-вероятностной модели - это возможность результатов выйти за интервал [0;1]. В оцененной модели прогнозы лежат в диапазоне от 0,405 до 1,208, доля прогнозов вне $[0, 1]$ (все они превышают единицу) составляет 3,3%. Второй недостаток модели заключается в том, что дисперсия ошибки зависит от регрессора и таким образом МНК оценки перестают быть эффективными (хоть и остаются несмещенными и состоятельными).

Интерпретировать мы можем оценки линейных коэффициентов, так как они показывают изменение вероятности того, что игра не разочаровала при росте переменной на единицу. Нелинейно входящие коэффициенты интерпретируются через предельные эффекты. Значимость с обычной оценкой ковариационной матрицы интерпретировать нельзя, так как из-за гетероскедастичности стандартные ошибки становятся несостоятельными. Альтернативно можно оценить ковариационную матрицу через робастную оценку матрицы или с помощью бутстрапа. Коэффициент детерминации и F-статистику так же проинтерпретировать напрямую нельзя, вместо этого можно посмотреть на долю верных прогнозов, а гипотезу о совместной значимости проверить через тест Вальда.

Интерпретация линейных коэффициентов:

- $\hat{\beta}_2 = 0{,}00246$: для игроков, выбравших собак, рост дохода на 1 тыс. руб. связан с увеличением вероятности того, что игра не разочаровала, в среднем на 0,25 п.п.;
- $\hat{\beta}_3 = -0{,}00164$: с ростом дохода на 1 тыс. руб. эффект выбора кошек на эту вероятность уменьшается на 0,16 п.п.;
- $\hat{\beta}_1 = 0{,}436$: для игрока с доходом, близким к нулю, выбор кошек вместо собак увеличивает вероятность того, что игра не разочаровала, на 43,6 п.п.

Задание 2.3.

Оцените и проинтерпретируйте, независимо от значимости, предельные эффекты на вероятность подписки каждой из используемых вами независимых переменных, предварительно записав формулы, по которым осуществлялся расчет. Результат представьте в форме таблицы, где для переменных, входящих нелинейно, рассчитан средний предельный эффект. Также, для этих переменных должно быть указано, при каких значениях независимой переменной их предельный эффект является положительным, а при каких - отрицательным.

Предельный эффект переменной x на вероятность того, что игра не разочаровала игрока, равен $\partial P(\text{satisfied}_i = 1 \mid X_i)/\partial x$. Дифференцируя уравнение (3), получаем:

$$\begin{aligned}
\text{ПЭ}_{\text{age},i} &= \beta_4 + 2\beta_5 \,\text{age}_i, \\
\text{ПЭ}_{\text{income},i} &= \beta_2 + \beta_3 \,\text{choice}_i, \\
\text{ПЭ}_{\text{choice},i} &= P(\text{satisfied}_i = 1 \mid \text{choice}_i = 1, \dots) - P(\text{satisfied}_i = 1 \mid \text{choice}_i = 0, \dots) = \beta_1 + \beta_3 \,\text{income}_i.
\end{aligned}$$

Поскольку переменная `choice` бинарная, ее предельный эффект определяется как разность вероятностей при $\text{choice}_i = 1$ и $\text{choice}_i = 0$ при прочих равных.

Все переменные входят в модель нелинейно или во взаимодействии, поэтому предельные эффекты различаются между игроками. В связи с этим рассчитаны средние предельные эффекты (СПЭ) - ПЭ, усредненные по всем игрокам выборки. В силу

линейности ПЭ по регрессорам СПЭ равен ПЭ, вычисленному в выборочных средних:

$$\text{СПЭ}_{\text{age}} = \hat{\beta}_4 + 2\hat{\beta}_5\,\overline{\text{age}} = 0{,}00769 + 2 \cdot (-0{,}0000576) \cdot 34{,}9 = 0{,}00367,$$
$$\text{СПЭ}_{\text{income}} = \hat{\beta}_2 + \hat{\beta}_3\,\overline{\text{choice}} = 0{,}00246 + (-0{,}00164) \cdot 0{,}571 = 0{,}00153,$$
$$\text{СПЭ}_{\text{choice}} = \hat{\beta}_1 + \hat{\beta}_3\,\overline{\text{income}} = 0{,}43647 + (-0{,}00164) \cdot 28{,}3 = 0{,}39011.$$

Знак ПЭ меняется в точках, где ПЭ обращается в ноль:

$$\text{age}^* = -\frac{\hat{\beta}_4}{2\hat{\beta}_5} = 66{,}8 \text{ лет}, \qquad \text{income}^* = -\frac{\hat{\beta}_1}{\hat{\beta}_3} = 266{,}7 \text{ тыс. руб.}$$

Предельный эффект дохода зависит только от выбора персонажей и равен $\hat{\beta}_2 = 0{,}00246$ для игроков, выбравших собак, и $\hat{\beta}_2 + \hat{\beta}_3 = 0{,}00083$ для выбравших кошек, то есть положителен в обеих группах. Результаты приведены в таблице 4.

Таблица 4: Средние предельные эффекты в ЛВМ

Переменная	СПЭ	Знак ПЭ
Возраст, лет	0.00367	> 0 при возрасте $<$ 66,8 лет; < 0 при возрасте $>$ 66,8 лет
Доход, тыс. руб.	0.00153	всегда > 0: собаки - 0.00246, кошки - 0.00083
Выбор кошек	0.39011	> 0 при доходе $<$ 266,7 тыс. руб.; < 0 при доходе $>$ 266,7 тыс. руб.

Согласно таблице 4, увеличение возраста на один год в среднем связано с ростом вероятности того, что игра не разочаровала игрока, на 0,37 п.п. Этот эффект положителен для игроков младше 66,8 лет и отрицателен для более старших, к которым относится лишь 1,6% выборки. Рост дохода на 1 тыс. руб. в среднем увеличивает эту вероятность на 0,15 п.п., причем для игроков, выбравших собак, эффект втрое сильнее (0,25 п.п.), чем для выбравших кошек (0,08 п.п.). Выбор кошек вместо собак в среднем повышает вероятность того, что игра не разочаровала, на 39 п.п.; этот эффект ослабевает с ростом дохода и становится отрицательным лишь при доходе выше 266,7 тыс. руб.

Задание 2.4*.

Протестируйте гипотезы о значимости коэффициентов с помощью бутстрапа. Результат представьте в форме таблицы. При этом предварительно (словами или самостоятельно нарисованной схемой) опишите алгоритм, который вы использовали для построения бутстрапированных доверительных интервалов.

Для проверки гипотез $H_0\colon \beta_j = 0$ против $H_1\colon \beta_j \neq 0$, $j = 0, \ldots, 5$, использован парный бутстрап с построением перцентильных доверительных интервалов. Алгоритм:

1. Из исходной выборки объема $n = 5000$ случайным образом с возвращением извлекаются n наблюдений

2. По бутстрап-выборке методом МНК оценивается ЛВМ (3) и сохраняется вектор оценок $\hat{\beta}^{*(b)}$.

3. Шаги 1–2 повторяются $B = 1000$ раз, $b = 1, \ldots, B$

4. Бутстрап-оценка стандартной ошибки $\hat{\beta}_j$ - выборочное стандартное отклонение $\hat{\beta}_j^{*(1)}, \ldots, \hat{\beta}_j^{*(B)}$.

5. 95%-й доверительный интервал для β_j задается 2,5%- и 97,5%-квантилями бутстрап-распределения: $\left[\hat{\beta}^*_{j,(0{,}025)};\ \hat{\beta}^*_{j,(0{,}975)}\right]$.

6. Нулевая гипотеза $H_0\colon \beta_j = 0$ отвергается на уровне значимости 5%, если ноль не принадлежит этому интервалу.

Результаты приведены в таблице 5.

Таблица 5: Бутстрап-оценки стандартных ошибок и 95%-е доверительные интервалы коэффициентов ЛВМ ($B = 1000$)

	Оценка	Ст. ошибка		95%-й дов. интервал	H_0
		обычная	бутстрап		
Константа	0.27804	0.04040	0.04027	[0.20005; 0.35698]	отверг.
Выбор кошек (choice)	0.43647	0.01741	0.01844	[0.40048; 0.47255]	отверг.
Доход, тыс. руб.	0.00246	0.00039	0.00050	[0.00160; 0.00352]	отверг.
Выбор кошек × доход	-0.00164	0.00049	0.00052	[−0.00274; −0.00072]	отверг.
Возраст, лет	0.00769	0.00222	0.00214	[0.00341; 0.01197]	отверг.
Возраст^2	-0.0000576	0.0000277	0.0000262	[−0.0001087; −0.0000045]	отверг.

Как видно из таблицы 5, ни один из бутстрап-интервалов не содержит ноль, поэтому на уровне значимости 5% гипотеза о равенстве нулю отвергается для всех коэффициентов модели. В целом, стандартные ошибки бутстрапа довольно близки к робастным и заметно выше обычных, что согласуется с гетероскедастичностью.

Задание 2.5**.

Протестируйте гипотезы о значимости коэффициентов используя состоятельную (скорректированную на гетероскедастичность) оценку асимптотической ковариационной матрицы. Результат представьте в форме таблицы (в том числе с p-value), предварительно выписав используемую для расчетов формулу.

Используется состоятельная в условиях гетероскедастичности оценка асимптотической ковариационной матрицы МНК-оценок (оценка Уайта, HC0):

$$\widehat{\mathrm{Var}}_{HC}(\hat{\beta}) = (X^\top X)^{-1} \left(\sum_{i=1}^{n} \hat{\varepsilon}_i^2 \, X_i X_i^\top \right) (X^\top X)^{-1}, \tag{4}$$

где X - матрица регрессоров размера $n \times 6$, X_i - вектор регрессоров игрока i (столбец), $\hat{\varepsilon}_i = \text{satisfied}_i - X_i^\top \hat{\beta}$ - остаток МНК, $n = 5000$. В отличие от обычной оценки $\hat{\sigma}^2 (X^\top X)^{-1}$, где дисперсия ошибки предполагается одинаковой для всех наблюдений,

здесь для каждого наблюдения используется свой квадрат остатка, что допускает гетероскедастичность.

Робастная стандартная ошибка $se_{HC}(\hat{\beta}_j)$ - корень из j-го диагонального элемента матрицы (4). Тестовая статистика:

$$z_j = \frac{\hat{\beta}_j}{se_{HC}(\hat{\beta}_j)} \xrightarrow{d} N(0,1) \quad \text{при верной } H_0.$$

Гипотеза H_0 отвергается на уровне значимости 5%, если $|z_j| > 1{,}96$ (p-value $< 0{,}05$). Результаты приведены в таблице 6.

Таблица 6: Оценки ЛВМ с робастными (HC0) стандартными ошибками

	Оценка	Ст. ошибка		z	p-value
		обычная	робастная		
Константа	0.27804	0.04040	0.04133	6.727	< 0.001
Выбор кошек (choice)	0.43647	0.01741	0.01864	23.420	< 0.001
Доход, тыс. руб.	0.00246	0.00039	0.00049	5.076	< 0.001
Выбор кошек × доход	-0.00164	0.00049	0.00052	-3.174	0.002
Возраст, лет	0.00769	0.00222	0.00220	3.499	< 0.001
Возраст^2	-0.0000576	0.0000277	0.0000270	-2.136	0.033
Робастный тест Вальда: $W = 1414{,}2$, $\chi^2(5)$, p-value $< 0{,}001$					

Согласно таблице 6, при использовании робастных стандартных ошибок все коэффициенты модели остаются значимыми на уровне 5%. Робастные стандартные ошибки близки к обычным и к бутстрап-оценкам (таблица 5).

Также проверена гипотеза о совместной незначимости всех коэффициентов, кроме константы, $H_0\colon \beta_1 = \cdots = \beta_5 = 0$, с помощью робастного теста Вальда:

$$W = (R\hat{\beta})^\top \left(R \widehat{\mathrm{Var}}_{HC}(\hat{\beta})\, R^\top \right)^{-1} (R\hat{\beta}) \xrightarrow{d} \chi^2(5) \quad \text{при верной } H_0,$$

где R - матрица размера 5×6, выделяющая коэффициенты $\beta_1, \ldots, \beta_5$. Полученное значение $W = 1414{,}2$ (p-value $< 0{,}001$) означает, что гипотеза о совместной незначимости отвергается.

Часть 3. Пробит модель

Задание 3.1.

Оцените пробит модель бинарного выбора. Предварительно запишите максимизируемую функцию правдоподобия (поясните все используемые обозначения), указав оцениваемые параметры и метод получения оценок, а также их основные свойства. Результат представьте в форме таблицы (можно, например, использовать выдачу из stata, R или python).

В пробит-модели предполагается, что вероятность того, что игра не разочаровала игрока, задается функцией стандартного нормального распределения:

$$\begin{aligned} P(\text{satisfied}_i = 1 \mid X_i) &= \Phi(X_i^\top \beta), \\ X_i^\top \beta &= \beta_0 + \beta_1 \,\text{choice}_i + \beta_2 \,\text{income}_i + \beta_3 \,\text{choice}_i \cdot \text{income}_i \\ &\quad + \beta_4 \,\text{age}_i + \beta_5 \,\text{age}_i^2, \end{aligned} \tag{5}$$

где $\Phi(\cdot)$ - функция распределения стандартного нормального закона, X_i - вектор регрессоров игрока i (включая единицу для константы), $\beta = (\beta_0, \ldots, \beta_5)^\top$ - вектор оцениваемых параметров; остальные обозначения совпадают с уравнением (1). Модель можно также записать через латентную переменную: $\text{satisfied}_i^* = X_i^\top \beta + \varepsilon_i$, $\varepsilon_i \sim N(0,1)$, $\text{satisfied}_i = 1$, если $\text{satisfied}_i^* > 0$, и 0 иначе.

Параметры оцениваются методом максимального правдоподобия (ММП). Наблюдения независимы, а satisfied_i имеет распределение Бернулли с вероятностью успеха $\Phi(X_i^\top \beta)$, поэтому функция правдоподобия имеет вид

$$L(\beta) = \prod_{i=1}^{n} \Phi(X_i^\top \beta)^{\text{satisfied}_i} \left[1 - \Phi(X_i^\top \beta)\right]^{1-\text{satisfied}_i},$$

а максимизируется ее логарифм:

$$\ln L(\beta) = \sum_{i=1}^{n} \Big[\text{satisfied}_i \ln \Phi(X_i^\top \beta) + (1 - \text{satisfied}_i) \ln \big(1 - \Phi(X_i^\top \beta)\big)\Big] \;\to\; \max_\beta,$$

где $n = 5000$. Аналитического решения задача не имеет, поэтому максимум находится численно (методом Ньютона). Оценка $\hat{\beta}_{ML}$ при верной спецификации модели обладает следующими свойствами: она *состоятельна*, *асимптотически нормальна* и *асимптотически эффективна* (ее асимптотическая ковариационная матрица равна обратной информационной матрице Фишера). В конечных выборках оценка, вообще говоря, смещена, поэтому значимость коэффициентов проверяется с помощью асимптотических z-статистик. Результаты оценивания представлены в таблице 7.

Согласно таблице 7, на уровне значимости 5% значимы коэффициенты при выборе кошек, доходе и возрасте, тогда как коэффициенты при переменной взаимодействия и квадрате возраста незначимы. Тест отношения правдоподобия $LR = 2(\ln L - \ln L_0)$, где $\ln L_0 = -2787{,}2$ - логарифм правдоподобия модели с одной константой, имеет при верной $H_0\colon \beta_1 = \cdots = \beta_5 = 0$ асимптотическое распределение $\chi^2(5)$. Полученное значение 1245,6 позволяет отвергнуть гипотезу о совместной незначимости коэффициентов.

Таблица 7: Оценки пробит-модели (ММП)

	Оценка	Ст. ошибка	z	p-value
Константа	-0.78520	0.16378	-4.794	< 0.001
Выбор кошек (choice)	1.34659	0.07705	17.477	< 0.001
Доход, тыс. руб.	0.00666	0.00140	4.746	< 0.001
Выбор кошек × доход	0.00153	0.00244	0.627	0.530
Возраст, лет	0.02687	0.00922	2.913	0.004
Возраст^2	-0.00017	0.00012	-1.465	0.143
Число наблюдений: 5000; $\ln L = -2164{,}4$; псевдо-R^2 Макфаддена = 0,224				
LR-тест: $LR = 1245{,}6$, $\chi^2(5)$, p-value $< 0{,}001$				

Задание 3.2.

Проинтерпретируйте оценки коэффициентов для каждой независимой переменной. Поясните, как полученные результаты соотносятся с высказанными вами ранее предположениями.

При интерпретации коэффициентов пробит-моделей нужно быть предельно осторожным, так как она очевидно (или нет) отличается от линейной и показывает влияние регрессоров на индекс $X_i^\top \beta$ (латентную удовлетворенность satisfied_i^*). Поскольку $\Phi(\cdot)$ - возрастающая функция, знак коэффициента при линейно входящей переменной совпадает со знаком ее влияния на вероятность того, что игра не разочаровала игрока, а величина эффекта на вероятность определяется предельными эффектами. Интерпретация оценок из таблицы 7:

1. Выбор кошек ($\hat{\beta}_1 = 1{,}347$, значим): выбор кошек вместо собак повышает вероятность того, что игра не разочаровала игрока. Это согласуется с выдвинутой гипотезой о положительном эффекте.

2. Доход ($\hat{\beta}_2 = 0{,}0067$, значим): для игроков, выбравших собак, рост дохода повышает вероятность того, что игра не разочаровала. Это противоречит гипотезе об отрицательном эффекте (более высоких ожиданиях обеспеченных игроков). Это может быть связано с тем, что более обеспеченные игроки располагают более мощными компьютерами, на которых бета-версия работает стабильнее, что перевешивает эффект завышенных ожиданий.

3. Взаимодействие выбора кошек и дохода ($\hat{\beta}_3 = 0{,}0015$, незначим): оснований считать, что влияние выбора кошек на индекс зависит от дохода, нет. Гипотеза об ослаблении эффекта выбора кошек с ростом дохода не подтверждается. В отличие от ЛВМ, где соответствующий коэффициент был отрицательным и значимым (таблица 3), в пробит-модели часть этого эффекта объясняется нелинейностью самой функции $\Phi(\cdot)$: у обеспеченных игроков, выбравших кошек, вероятность и так близка к единице, поэтому дополнительный эффект выбора кошек на вероятность у них меньше даже без отрицательного коэффициента взаимодействия.

4. Возраст ($\hat{\beta}_4 = 0{,}0269$, значим; $\hat{\beta}_5 = -0{,}00017$ (квадрат возраста), незначим). Следовательно, в наблюдаемом диапазоне возраста вероятность того, что игра не разочаровала, растет с возрастом, а квадратичная составляющая статистически незначима. Гипотеза об отрицательном квадратичном влиянии возраста (отрицательный β_4 и положительный β_5) не подтверждается: более старшие игроки, напротив, оценивают игру выше.

Таким образом, из выдвинутых гипотез подтвердилась только гипотеза о положительном влиянии выбора кошек, которая является главной для заказчика.

Задание 3.3.

Оцените вероятность того, что индивид удовлетворен игрой, для индивида с произвольными (например, вашими) характеристиками. Запишите формулу, по которой осуществлялся расчет (подставьте в нее полученные реализации оценок).

Рассмотрим индивида с характеристиками, приведенными в таблице 13 приложения: 21-летний игрок с доходом 70 тыс. руб., проходивший игру за кошек. Согласно пробит-модели (5), оценка вероятности того, что игра не разочаровала такого игрока, равна

$$\hat{P}(\text{satisfied} = 1 \mid X) = \Phi\big(X^\top \hat{\beta}\big),$$

где X - вектор характеристик индивида, $\hat{\beta}$ - оценки из таблицы 7. Подставляя значения, получаем:

$$\begin{aligned} X^\top \hat{\beta} &= -0{,}7852 + 1{,}3466 \cdot 1 + 0{,}00666 \cdot 70 + 0{,}00153 \cdot 1 \cdot 70 \\ &\quad + 0{,}02687 \cdot 21 - 0{,}000171 \cdot 21^2 = 1{,}6231, \\ \hat{P}(\text{satisfied} = 1 \mid X) &= \Phi(1{,}6231) = 0{,}948. \end{aligned}$$

Таким образом, вероятность того, что игра не разочаровала 21-летнего игрока с доходом 70 тыс. руб., выбравшего кошек, составляет около 95%, что существенно выше доли таких игроков в выборке в целом (75,4%). Столь высокая вероятность объясняется сочетанием выбора кошек и высокого дохода: доход 70 тыс. руб. превышает доход 95% игроков выборки.

Задание 3.4.

Для произвольных непрерывной и бинарной независимых переменных оцените средний предельный эффект на вероятность удовлетворенности игрой, предварительно записав формулы (с подставленными реализациями оценок), по которым осуществлялся расчет. Результат представьте в форме таблицы.

Рассчитаем средние предельные эффекты (СПЭ) возраста (непрерывная переменная) и выбора кошек (бинарная переменная). Обозначим $X_i^\top \hat{\beta}$ - оцененный индекс пробит-модели (5) для игрока i, $\phi(\cdot)$ - плотность стандартного нормального распределения, $n = 5000$.

Поскольку возраст входит в индекс в виде $\beta_4 \,\text{age} + \beta_5 \,\text{age}^2$, предельный эффект для игрока i равен

$$\begin{aligned} \text{ПЭ}_{\text{age},i} &= \frac{\partial \Phi(X_i^\top \beta)}{\partial \,\text{age}_i} = \phi(X_i^\top \hat{\beta}) \left(\hat{\beta}_4 + 2\hat{\beta}_5 \,\text{age}_i\right) \\ &= \phi(X_i^\top \hat{\beta}) \left(0{,}02687 - 0{,}000343 \,\text{age}_i\right), \end{aligned}$$

а средний предельный эффект - его среднее по выборке:

$$\text{СПЭ}_{\text{age}} = \frac{1}{n} \sum_{i=1}^{n} \phi(X_i^\top \hat{\beta}) \left(0{,}02687 - 0{,}000343 \,\text{age}_i\right) = 0{,}00379.$$

Для бинарной переменной предельный эффект определяется как разность вероятностей при $\text{choice}_i = 1$ и $\text{choice}_i = 0$ при прочих характеристиках игрока:

$$\begin{aligned}\text{ПЭ}_{\text{choice},i} &= \Phi\big(\hat\beta_0 + \hat\beta_1 + (\hat\beta_2 + \hat\beta_3)\,\text{income}_i + \hat\beta_4\,\text{age}_i + \hat\beta_5\,\text{age}_i^2\big) \\ &\quad - \Phi\big(\hat\beta_0 + \hat\beta_2\,\text{income}_i + \hat\beta_4\,\text{age}_i + \hat\beta_5\,\text{age}_i^2\big) \\ &= \Phi\big(0{,}5614 + 0{,}00819\,\text{income}_i + 0{,}02687\,\text{age}_i - 0{,}000171\,\text{age}_i^2\big) \\ &\quad - \Phi\big(-0{,}7852 + 0{,}00666\,\text{income}_i + 0{,}02687\,\text{age}_i - 0{,}000171\,\text{age}_i^2\big),\end{aligned}$$

$$\text{СПЭ}_{\text{choice}} = \frac{1}{n}\sum_{i=1}^{n} \text{ПЭ}_{\text{choice},i} = 0{,}38866.$$

Здесь $0{,}5614 = \hat\beta_0 + \hat\beta_1$ и $0{,}00819 = \hat\beta_2 + \hat\beta_3$. Результаты приведены в таблице 8.

Таблица 8: Средние предельные эффекты в пробит-модели и ЛВМ

Переменная	Пробит	ЛВМ (таблица 4)
Возраст, лет	0.00379	0.00367
Выбор кошек (choice)	0.38866	0.39011

Согласно таблице 8, увеличение возраста на один год в среднем повышает вероятность того, что игра не разочаровала игрока, на 0,38 п.п., а выбор кошек вместо собак в среднем повышает эту вероятность на 38,9 п.п. Средние предельные эффекты пробит-модели практически совпадают с ЛВМ: для оценки средних эффектов ЛВМ дает хорошее приближение, а различия между моделями проявляются главным образом для отдельных игроков, вероятность для которых близка к 0 или 1 (если игрок удовлетворен игрой, изменение его возраста мало меняет эту вероятность).

Задание 3.5.

Посчитайте долю верных прогнозов и сопоставьте ее с результатом наивного прогноза и линейно-вероятностной модели. Сделайте вывод о предсказательной силе пробит модели.

Для построения прогноза выбирается порог 0.5, то есть если $\hat P(\text{satisfied}_i = 1 \mid X_i) > 0{,}5$, то $\widehat{\text{satisfied}}_i = 1$ и 0, если меньше.

Наивный прогноз приписывает всем игрокам наиболее частое значение ($\text{satisfied}_i = 1$), поэтому его доля верных прогнозов равна доле игроков, которых игра не разочаровала. Результаты приведены в таблице 9.

Таблица 9: Доля верных прогнозов (порог 0,5)

Модель	Доля верных прогнозов	Доля верных среди игроков, которых игра	
		разочаровала (0)	не разочаровала (1)
Наивный прогноз	0.754	0.000	1.000
ЛВМ	0.783	0.417	0.902
Пробит	0.782	0.458	0.888

Как видно из таблицы 9, пробит-модель верно предсказывает 78,2% наблюдений, что на 2,8 п.п. выше наивного прогноза (75,4%). Доля верных прогнозов ЛВМ практически такая же (78,3%). При этом пробит-модель лучше распознает игроков, которых игра разочаровала: она верно классифицирует 45,8% из них против 41,7% у ЛВМ, тогда как наивный прогноз не распознает ни одного такого игрока. Итого, пробит-модель обладает умеренной предсказательной силой: выигрыш относительно наивного прогноза невелик, однако, в отличие от наивного прогноза, модель позволяет выявить почти половину неудовлетворенных игроков.

Задание 3.6.

На уровне значимости 5% проверьте гипотезу о том, что предельный эффект на вероятность удовлетворенности игрой по произвольной (на ваш выбор) независимой переменной является значимым для индивида с произвольными характеристиками.

Проверим значимость предельного эффекта возраста для индивида из таблицы 13 (21 год, доход 70 тыс. руб., выбор кошек). Обозначим $X = (1,\ 1,\ 70,\ 70,\ 21,\ 21^2)^\top$ - вектор его характеристик. Предельный эффект возраста для этого индивида является функцией параметров:

$$\text{ПЭ}_{\text{age}}(\beta) = \phi(X^\top\beta)\,(\beta_4 + 2\beta_5 \cdot 21).$$

Подставляя оценки, получаем $X^\top\hat{\beta} = 1{,}6231$, $\phi(1{,}6231) = 0{,}1069$ и

$$\widehat{\text{ПЭ}}_{\text{age}} = 0{,}1069 \cdot (0{,}02687 - 2 \cdot 0{,}000171 \cdot 21) = 0{,}1069 \cdot 0{,}01967 = 0{,}00210.$$

Гипотезы: $H_0\colon \text{ПЭ}_{\text{age}} = 0$ против $H_1\colon \text{ПЭ}_{\text{age}} \neq 0$. Тестовая статистика:

$$z = \frac{\widehat{\text{ПЭ}}_{\text{age}}}{se\big(\widehat{\text{ПЭ}}_{\text{age}}\big)} \xrightarrow{d} N(0,1) \quad \text{при верной } H_0,$$

где стандартная ошибка рассчитана дельта-методом:

$$\widehat{\text{Var}}\big(\widehat{\text{ПЭ}}_{\text{age}}\big) = \nabla\text{ПЭ}_{\text{age}}(\hat{\beta})^\top\, \widehat{\text{Var}}(\hat{\beta})\, \nabla\text{ПЭ}_{\text{age}}(\hat{\beta}),$$

$\widehat{\text{Var}}(\hat{\beta})$ - оценка асимптотической ковариационной матрицы ММП-оценок пробит-модели, $\nabla\text{ПЭ}_{\text{age}}(\hat{\beta})$ - вектор частных производных предельного эффекта по параметрам.

Получено $se\big(\widehat{\text{ПЭ}}_{\text{age}}\big) = 0{,}00062$, $z = 0{,}00210/0{,}00062 = 3{,}39$, p-value $= 0{,}0007$. Поскольку $|z| > 1{,}96$, на уровне значимости 5% нулевая гипотеза отвергается: предельный эффект возраста для данного индивида значим. Для 21-летнего игрока с доходом 70 тыс. руб., выбравшего кошек, увеличение возраста на один год повышает вероятность того, что игра не разочаровала, на 0,21 п.п. Эффект меньше среднего по выборке (0,38 п.п., таблица 8), поскольку вероятность не разочароваться игрой для этого игрока уже близка к единице (0,948) и плотность $\phi(X^\top\hat{\beta})$ мала.

Задание 3.7*.

Повторите предыдущий пункт для переменной, имеющей взаимодействие.

Проверим значимость предельного эффекта выбора кошек для того же индивида (таблица 13). Поскольку `choice` - бинарная переменная, входящая во взаимодействие с доходом, предельный эффект определяется как разность вероятностей того, что игра не разочаровала игрока, при choice = 1 и choice = 0 при неизменных доходе (70 тыс. руб.) и возрасте (21 год):

$$\text{ПЭ}_{\text{choice}}(\beta) = \Phi(X_1^\top \beta) - \Phi(X_0^\top \beta),$$

где $X_1 = (1,\ 1,\ 70,\ 70,\ 21,\ 21^2)^\top$ и $X_0 = (1,\ 0,\ 70,\ 0,\ 21,\ 21^2)^\top$ - векторы характеристик индивида при выборе кошек и собак соответственно. Взаимодействие учитывается тем, что при choice = 1 в индекс входит слагаемое $\beta_3 \cdot 70$, а при choice = 0 - нет. Подставляя оценки:

$$\begin{aligned} X_1^\top \hat\beta &= 1{,}6231, \qquad \Phi(1{,}6231) = 0{,}9477, \\ X_0^\top \hat\beta &= 0{,}1695, \qquad \Phi(0{,}1695) = 0{,}5673, \\ \widehat{\text{ПЭ}}_{\text{choice}} &= 0{,}9477 - 0{,}5673 = 0{,}3804. \end{aligned}$$

Гипотезы: $H_0\colon \text{ПЭ}_{\text{choice}} = 0$ против $H_1\colon \text{ПЭ}_{\text{choice}} \neq 0$. Тестовая статистика

$$z = \frac{\widehat{\text{ПЭ}}_{\text{choice}}}{se\big(\widehat{\text{ПЭ}}_{\text{choice}}\big)} \xrightarrow{d} N(0,1) \quad \text{при верной } H_0,$$

где стандартная ошибка рассчитана дельта-методом:

$$\begin{aligned} \nabla \text{ПЭ}_{\text{choice}}(\hat\beta) &= \phi(X_1^\top \hat\beta)\, X_1 - \phi(X_0^\top \hat\beta)\, X_0, \\ \widehat{\text{Var}}\big(\widehat{\text{ПЭ}}_{\text{choice}}\big) &= \nabla \text{ПЭ}_{\text{choice}}(\hat\beta)^\top\, \widehat{\text{Var}}(\hat\beta)\, \nabla \text{ПЭ}_{\text{choice}}(\hat\beta), \end{aligned}$$

$\widehat{\text{Var}}(\hat\beta)$ - оценка асимптотической ковариационной матрицы ММП-оценок пробит-модели.

Получено $se\big(\widehat{\text{ПЭ}}_{\text{choice}}\big) = 0{,}0292$, $z = 0{,}3804/0{,}0292 = 13{,}03$, p-value $< 0{,}001$. Поскольку $|z| > 1{,}96$, на уровне значимости 5% нулевая гипотеза отвергается: предельный эффект выбора кошек для данного индивида значим. Для 21-летнего игрока с доходом 70 тыс. руб. выбор кошек вместо собак повышает вероятность того, что игра не разочаровала, с 56,7% до 94,8%, то есть на 38 п.п.

Задание 3.8**.

Воспользуйтесь дельта-методом для того, чтобы вручную рассчитать асимптотическую дисперсию предельного эффекта любой непрерывной переменной, входящей нелинейно. Запишите использовавшееся вами выражение, подставив в него численные значения оценок пробит модели.

Рассчитаем вручную асимптотическую дисперсию предельного эффекта возраста (непрерывной переменной, входящей нелинейно) для индивида из таблицы 13, $X = (1,\ 1,\ 70,\ 70,\ 21,\ 21^2)^\top$. Предельный эффект является функцией вектора параметров:

$$g(\beta) = \text{ПЭ}_{\text{age}}(\beta) = \phi(X^\top \beta)\,(\beta_4 + 2\beta_5 \cdot 21).$$

Согласно дельта-методу, если $\sqrt{n}(\hat\beta - \beta) \xrightarrow{d} N(0, \Sigma)$, то $g(\hat\beta)$ также асимптотически нормальна, и

$$\widehat{\text{Var}}\big(g(\hat\beta)\big) = \nabla g(\hat\beta)^\top\, \widehat{\text{Var}}(\hat\beta)\, \nabla g(\hat\beta) = \sum_{j=0}^{5} \sum_{k=0}^{5} \frac{\partial g}{\partial \beta_j}\, \frac{\partial g}{\partial \beta_k}\, \widehat{\text{Cov}}(\hat\beta_j, \hat\beta_k).$$

Учитывая, что $\phi'(z) = -z\,\phi(z)$, получаем для $j = 0, \ldots, 5$:

$$\frac{\partial g}{\partial \beta_j} = -X^\top\beta \cdot \phi(X^\top\beta)\,(\beta_4 + 2\beta_5 \cdot 21)\,X_j + \phi(X^\top\beta) \cdot \frac{\partial(\beta_4 + 2\beta_5 \cdot 21)}{\partial \beta_j},$$

где последняя производная равна 1 при $j = 4$, $2 \cdot 21 = 42$ при $j = 5$ и 0 иначе. Подставим оценки: $X^\top\hat\beta = 1{,}6231$, $\phi(1{,}6231) = 0{,}10687$, $\hat\beta_4 + 2\hat\beta_5 \cdot 21 = 0{,}01967$, откуда общий множитель $c = -1{,}6231 \cdot 0{,}10687 \cdot 0{,}01967 = -0{,}003412$ и

$$\begin{aligned}
&\partial g/\partial\beta_0 = c \cdot 1 = -0{,}00341, && \partial g/\partial\beta_1 = c \cdot 1 = -0{,}00341,\\
&\partial g/\partial\beta_2 = c \cdot 70 = -0{,}23884, && \partial g/\partial\beta_3 = c \cdot 70 = -0{,}23884,\\
&\partial g/\partial\beta_4 = c \cdot 21 + 0{,}10687 = 0{,}03522, && \partial g/\partial\beta_5 = c \cdot 441 + 0{,}10687 \cdot 42 = 2{,}98379.
\end{aligned}$$

Оценка асимптотической ковариационной матрицы ММП-оценок пробит-модели (порядок параметров $\beta_0, \ldots, \beta_5$):

$$\widehat{\mathrm{Var}}(\hat\beta) = \begin{pmatrix}
2{,}682\text{e-}2 & -2{,}129\text{e-}3 & -4{,}983\text{e-}5 & 4{,}939\text{e-}5 & -1{,}431\text{e-}3 & 1{,}741\text{e-}5\\
-2{,}129\text{e-}3 & 5{,}937\text{e-}3 & 5{,}117\text{e-}5 & -1{,}521\text{e-}4 & 3{,}139\text{e-}6 & -4{,}160\text{e-}8\\
-4{,}983\text{e-}5 & 5{,}117\text{e-}5 & 1{,}968\text{e-}6 & -1{,}968\text{e-}6 & -7{,}586\text{e-}8 & 9{,}025\text{e-}10\\
4{,}939\text{e-}5 & -1{,}521\text{e-}4 & -1{,}968\text{e-}6 & 5{,}932\text{e-}6 & 1{,}239\text{e-}8 & 1{,}035\text{e-}9\\
-1{,}431\text{e-}3 & 3{,}139\text{e-}6 & -7{,}586\text{e-}8 & 1{,}239\text{e-}8 & 8{,}505\text{e-}5 & -1{,}064\text{e-}6\\
1{,}741\text{e-}5 & -4{,}160\text{e-}8 & 9{,}025\text{e-}10 & 1{,}035\text{e-}9 & -1{,}064\text{e-}6 & 1{,}368\text{e-}8
\end{pmatrix}$$

(запись ae-k означает $a \cdot 10^{-k}$).

Подставляя градиент и матрицу в формулу дельта-метода:

$$\widehat{\mathrm{Var}}\big(\widehat{\Pi\Theta}_{\mathrm{age}}\big) = \nabla g(\hat\beta)^\top\,\widehat{\mathrm{Var}}(\hat\beta)\,\nabla g(\hat\beta) = 3{,}844 \cdot 10^{-7},$$

откуда $se\big(\widehat{\Pi\Theta}_{\mathrm{age}}\big) = \sqrt{3{,}844 \cdot 10^{-7}} = 0{,}00062$.

Часть 4. Логит модель

Задание 4.1.

Оцените логит модель, предварительно записав максимизируемую функцию правдоподобия и указав, чем логит модель отличается от пробит модели. Результат представьте в форме таблицы (можно, например, использовать выдачу из stata, R или python).

В логит-модели вероятность того, что игра не разочаровала игрока, задается логистической функцией распределения:

$$P(\text{satisfied}_i = 1 \mid X_i) = \Lambda(X_i^\top \beta) = \frac{e^{X_i^\top \beta}}{1 + e^{X_i^\top \beta}}, \tag{6}$$

где индекс $X_i^\top \beta$ имеет тот же вид, что в пробит-модели (5), $\beta = (\beta_0, \ldots, \beta_5)^\top$ - вектор оцениваемых параметров. Параметры оцениваются методом максимального правдоподобия; максимизируемая логарифмическая функция правдоподобия:

$$\ln L(\beta) = \sum_{i=1}^{n} \Big[\text{satisfied}_i \ln \Lambda(X_i^\top \beta) + (1 - \text{satisfied}_i) \ln \big(1 - \Lambda(X_i^\top \beta)\big)\Big] \;\to\; \max_\beta,$$

где $n = 5000$, остальные обозначения совпадают с заданием 3.1.

Логит и пробит модели как минимум по-разному называются, а как максимум имеют несколько существенных различий: Во-первых, ошибка ε_i имеет логистическое распределение (с дисперсией $\pi^2/3$), а не стандартное нормальное, следовательно, модель немного по другому считает вероятности. Во-вторых, логит-модели удобно интерпретировать через логарифм отношения шансов, так как он линейно зависит от регрессоров.

Результаты оценивания представлены в таблице 10.

Таблица 10: Оценки логит-модели (ММП)

	Оценка	Ст. ошибка	z	p-value
Константа	-1.35808	0.28366	-4.788	< 0.001
Выбор кошек (choice)	2.25752	0.14916	15.135	< 0.001
Доход, тыс. руб.	0.01095	0.00234	4.679	< 0.001
Выбор кошек × доход	0.00689	0.00503	1.369	0.171
Возраст, лет	0.04719	0.01607	2.937	0.003
Возраст^2	-0.00031	0.00020	-1.507	0.132
Число наблюдений: 5000; $\ln L = -2164{,}6$; псевдо-R^2 Макфаддена $= 0{,}223$				
LR-тест: $LR = 1245{,}3$, $\chi^2(5)$, p-value $< 0{,}001$				

Результаты логит-модели в целом совпадают с пробит-моделью (таблица 7): на уровне 5% значимы коэффициенты при выборе кошек, доходе и возрасте, а коэффициенты при переменной взаимодействия и квадрате возраста незначимы; знаки всех коэффициентов совпадают. Значения логарифма правдоподобия двух моделей практически равны ($-2164{,}6$ и $-2164{,}4$), то есть модели одинаково хорошо описывают данные.

Задание 4.2.

Проинтерпретируйте значения оценок изменений в отношениях шансов по каждой независимой переменной, входящей линейно.

В логит-модели логарифм шансов линеен по регрессорам:

$$\ln \frac{P(\text{satisfied}_i = 1 \mid X_i)}{1 - P(\text{satisfied}_i = 1 \mid X_i)} = X_i^\top \beta,$$

поэтому при росте линейного регрессора на единицу шансы того, что игра не разочаровала игрока, умножаются на e^β (отношение шансов, OR). Линейно (в первой степени) в индекс входят выбор кошек и доход; однако они входят и во взаимодействие, поэтому отношение шансов по каждой из них зависит от значения другой. Используются оценки из таблицы 10.

Доход. Для игроков, выбравших собак, $e^{\hat\beta_2} = e^{0{,}01095} = 1{,}011$: рост дохода на 1 тыс. руб. увеличивает шансы того, что игра не разочаровала, на 1,1%. Для игроков, выбравших кошек, $e^{\hat\beta_2 + \hat\beta_3} = e^{0{,}01783} = 1{,}018$, то есть шансы растут на 1,8% на каждую тысячу рублей.

Выбор кошек. $e^{\hat\beta_1} = e^{2{,}2575} = 9{,}56$: для игрока с доходом, близким к нулю, выбор кошек вместо собак увеличивает шансы того, что игра не разочаровала, в 9,6 раза. С учетом взаимодействия для игрока со средним доходом (28,3 тыс. руб.) отношение шансов равно $e^{\hat\beta_1 + \hat\beta_3 \cdot 28{,}3} = 11{,}62$, то есть шансы возрастают в 11,6 раза.

Взаимодействие. $e^{\hat\beta_3} = e^{0{,}00689} = 1{,}007$: с ростом дохода на 1 тыс. руб. отношение шансов по выбору кошек увеличивается на 0,7%. Однако коэффициент β_3 незначим (p-value = 0,171), поэтому статистических оснований считать, что эффект выбора кошек на шансы зависит от дохода, нет.

Задание 4.3*.

Запишите выражения для расчета изменений в отношениях шансов по каждой независимой переменной, входящей нелинейно. Рассчитайте соответствующие предельные эффекты для индивида с произвольными характеристиками. Результаты расчетов представьте в форме таблицы.

Возраст входит в индекс логит-модели нелинейно ($\beta_4 \,\text{age} + \beta_5 \,\text{age}^2$), поэтому изменение отношения шансов при росте возраста на один год зависит от исходного возраста a:

$$\text{OR}_{\text{age}}(a) = \frac{\text{Odds}(\text{age} = a+1)}{\text{Odds}(\text{age} = a)} = \frac{e^{\beta_4(a+1) + \beta_5 (a+1)^2}}{e^{\beta_4 a + \beta_5 a^2}} = e^{\beta_4 + \beta_5 (2a+1)},$$

где Odds $= P/(1-P)$ - шансы того, что игра не разочаровала игрока, при прочих равных характеристиках. Аналогично, из-за взаимодействия выбора кошек и дохода отношения шансов по этим переменным зависят друг от друга:

$$\text{OR}_{\text{income}}(\text{choice}) = e^{\beta_2 + \beta_3 \,\text{choice}}, \qquad \text{OR}_{\text{choice}}(\text{income}) = e^{\beta_1 + \beta_3 \,\text{income}}.$$

Предельные эффекты на вероятность в логит-модели с учетом того, что $\Lambda'(z) = \Lambda(z)\,(1 - \Lambda(z))$:

$$\begin{gathered}
\text{ПЭ}_{\text{age}} = \Lambda(X^\top\beta)\big(1 - \Lambda(X^\top\beta)\big)(\beta_4 + 2\beta_5 \,\text{age}), \\
\text{ПЭ}_{\text{income}} = \Lambda(X^\top\beta)\big(1 - \Lambda(X^\top\beta)\big)(\beta_2 + \beta_3 \,\text{choice}), \\
\text{ПЭ}_{\text{choice}} = \Lambda(X_1^\top\beta) - \Lambda(X_0^\top\beta),
\end{gathered}$$

где X_1 и X_0 - векторы характеристик индивида при выборе кошек и собак (см. задание 3.7).

Для индивида из таблицы 13 (21 год, доход 70 тыс. руб., выбор кошек) с оценками из таблицы 10 получаем $X^\top \hat{\beta} = 3{,}003$, $\Lambda(3{,}003) = 0{,}9527$ и, например,

$$\widehat{\mathrm{OR}}_{\mathrm{age}}(21) = e^{0{,}04719 - 0{,}000308 \cdot 43} = 1{,}0345,$$
$$\widehat{\mathrm{ПЭ}}_{\mathrm{age}} = 0{,}9527 \cdot 0{,}0473 \cdot (0{,}04719 - 2 \cdot 0{,}000308 \cdot 21) = 0{,}00154.$$

Результаты для всех переменных приведены в таблице 11.

Таблица 11: Отношения шансов и предельные эффекты в логит-модели для индивида из таблицы 13

Переменная	Изменение отношения шансов	ПЭ на вероятность
Возраст (21 → 22 года)	1.0345	0.00154
Доход (+1 тыс. руб., при выборе кошек)	1.0180	0.00080
Выбор кошек (при доходе 70 тыс. руб.)	15.48	0.3872

Получается, что для нашего очень рандомного игрока увеличение возраста на один год повышает шансы того, что игра не разочаровала, на 3,5%, а рост дохода на 1 тыс. руб. - на 1,8%. Выбор кошек вместо собак увеличивает шансы в 15,5 раза, а вероятность - на 38,7 п.п. (с 56,5% до 95,3%), что близко к результату пробит-модели (38,0 п.п.). Из-за квадратичного слагаемого влияние возраста на шансы ослабевает с возрастом: в 21 год шансы растут на 3,5% за год, в более старшем возрасте - медленнее. Рост шансов прекращается ($\widehat{\mathrm{OR}}_{\mathrm{age}}(a) = 1$) примерно в 76 лет, а после этого возраста шансы начали бы снижаться. Поскольку максимальный возраст в выборке составляет 68 лет (хорошо, что в начале мы посмотрели описательные статистики!), для всех игроков выборки увеличение возраста повышает шансы того, что игра не разочаровала.

Задание 4.4**.

Для произвольной независимой переменной, входящей нелинейно, проверьте гипотезу о том, что при ее изменении на единицу отношение шансов возрастет на 10%. Запишите тестовую статистику, а также формулу, по которой рассчитывалась стандартная ошибка оценки изменения отношений шансов.

Проверим гипотезу о том, что при увеличении возраста на один год отношение шансов возрастет на 10%. Поскольку возраст входит нелинейно, отношение шансов зависит от исходного возраста; рассмотрим индивида из таблицы 13 (21 год). Как мы ранее записали, $\mathrm{OR}_{\mathrm{age}}(21) = e^{\beta_4 + \beta_5(2 \cdot 21 + 1)} = e^{\beta_4 + 43\beta_5}$.

Гипотезы: $H_0\colon \mathrm{OR}_{\mathrm{age}}(21) = 1{,}1$ против $H_1\colon \mathrm{OR}_{\mathrm{age}}(21) \neq 1{,}1$. Тестовая статистика:

$$z = \frac{\widehat{\mathrm{OR}}_{\mathrm{age}}(21) - 1{,}1}{se\big(\widehat{\mathrm{OR}}_{\mathrm{age}}(21)\big)} \xrightarrow{d} N(0,1) \quad \text{при верной } H_0.$$

Стандартная ошибка рассчитана дельта-методом. Обозначим $g(\beta) = e^{\beta_4 + 43\beta_5}$; ненулевые компоненты градиента: $\partial g/\partial \beta_4 = g(\beta)$, $\partial g/\partial \beta_5 = 43\, g(\beta)$. Тогда

$$\widehat{\mathrm{Var}}\big(\widehat{\mathrm{OR}}_{\mathrm{age}}(21)\big) = \widehat{\mathrm{OR}}_{\mathrm{age}}(21)^2 \Big(\widehat{\mathrm{Var}}(\hat{\beta}_4) + 43^2\, \widehat{\mathrm{Var}}(\hat{\beta}_5) + 2 \cdot 43\, \widehat{\mathrm{Cov}}(\hat{\beta}_4, \hat{\beta}_5) \Big),$$

где дисперсии и ковариация взяты из оценки асимптотической ковариационной матрицы ММП-оценок логит-модели. Подставляя оценки:

$$\begin{aligned}
\widehat{\mathrm{OR}}_{\mathrm{age}}(21) &= e^{0{,}04719-43\cdot 0{,}000308} = 1{,}0345,\\
\widehat{\mathrm{Var}}\big(\widehat{\mathrm{OR}}_{\mathrm{age}}(21)\big) &= 1{,}0345^2\big(2{,}581\cdot 10^{-4} + 1849\cdot 4{,}168\cdot 10^{-8} + 86\cdot(-3{,}235\cdot 10^{-6})\big)\\
&= 1{,}0345^2\cdot 5{,}700\cdot 10^{-5} = 6{,}10\cdot 10^{-5},\\
se\big(\widehat{\mathrm{OR}}_{\mathrm{age}}(21)\big) &= 0{,}00781,\\
z &= \frac{1{,}0345-1{,}1}{0{,}00781} = -8{,}38.
\end{aligned}$$

Поскольку $|z| = 8{,}38 > 1{,}96$ (p-value $< 0{,}001$), на уровне значимости 5% нулевая гипотеза отвергается. Для 21-летнего игрока увеличение возраста на один год повышает шансы того, что игра не разочаровала, примерно на 3,5%, что значимо меньше гипотетических 10%.

Приложение

Таблица 12: Описание переменных

Переменная	Описание
`game`	удовлетворенность игрой (0 — низкая, 1 — средняя, 2 — высокая)
`choice`	за кого проходил игру (1 — кошки, 0 — собаки)
`income`	доход, руб.
`age`	возраст, лет
`hours`	среднее число игровых часов в неделю
`health`	здоровье (bad — плохое, medium — среднее, good — хорошее)
`marriage`	семейный статус (1 — в браке, 0 — холост)
`chl`	наличие детей (1 — есть, 0 — нет)
`male`	пол (1 — мужской, 0 — женский)
`residence`	место проживания (capital — столица региона, city — город, village — деревня)
`cat`	наличие кота (1 — есть, 0 — нет)
`dog`	наличие собаки (1 — есть, 0 — нет)
`bugs`	число багов, с которыми столкнулся игрок
`price`	стоимость компьютера игрока, тыс. руб.[1]
`design`	вариант дизайна меню выбора, назначенный случайно (1 — первый, 0 — второй)
`educ`	образование (basic — среднее, vocational — среднее специальное, higher — высшее, phd — кандидат наук)

Таблица 13: Характеристики индивида, для которого рассчитываются вероятности и предельные эффекты

Характеристика	Значение
Выбор персонажей (`choice`)	1 (кошки)
Доход (`income`), тыс. руб.	70
Возраст (`age`), лет	21